


KI Python Tutor

Agentic AI · Demo Day · Juli 2026

🤖 Personalisiertes Python-Lernen mit KI-Agent



KI-TUTOR CHAT



CODE REVIEW



SKILL-TRACKING



AGENT-GEDÄCHTNIS

DAS PROBLEM — UND DIE LÖSUNG

Python lernen ist oft **frustrierend** — das muss nicht so sein

✖ DAS PROBLEM

**Kein Überblick über den eigenen Fortschritt**

Lernende wissen nicht, *wo sie stehen* und was als nächstes dran ist. Übungsblätter ohne Kontext.

**Generisches, nicht-personalisiertes Feedback**

Compiler-Fehler auf Englisch, keine Erklärung *warum* der Code falsch ist oder wie man es besser macht.

**Jede Lernsession beginnt bei Null**

KI-Chats kennen *keinen Lernverlauf* — man muss den Kontext bei jedem Gespräch neu erklären.

✔ DIE LÖSUNG

**Skill-Tree mit 37 Skills & Lernplan**

3 Level (Beginner → Advanced), Fortschritt-Score pro Skill, *personalisierter Wochenlernplan* mit Zeitschätzung.

**3-stufige Code-Review Chain**

Syntax-Fehler → PEP8-Stil → Best Practices — jede Ebene separat, mit Zeilennummer und Verbesserungsvorschlag *auf Deutsch*.

**KI erinnert sich — sitzungsübergreifend**

ConversationSummaryMemory: *"Letzte Woche hatten wir Loops — da hattest du Schwierigkeiten mit dem Index."*

FEATURES

Was der Tutor alles kann



CHAT-TUTOR

ReAct-Agent mit Werkzeugauswahl

Erklärt Konzepte, antwortet auf Code-Fragen, wählt selbst das passende Tool — Erklärung, Debugging oder Übung.



CODE-REVIEW CHAIN

3 Ebenen • 3 LLM-Aufrufe

Syntax ● → PEP8 / Stil ● → Best Practices ●
— jede Stufe bekommt den Summary der vorherigen als Kontext.



SKILL-TREE & ÜBUNGEN

37 Skills, 3 Level, progressiv

Beginner → Intermediate → Advanced. Jeder Skill hat Übungen mit bis zu 3 progressiven Hints und automatischer KI-Bewertung.



RAG-SYSTEM

PDF hochladen → Tutor nutzt es


Lernmaterialien per FAISS-Index indexiert. Der Tutor antwortet mit Bezug auf eigene Unterlagen:
"Auf Seite 9 steht..."



AGENT-GEDÄCHTNIS

ConversationSummaryMemory

Nach jedem Chat-Turn: LLM komprimiert Verlauf zu max. 2 Sätzen / 40 Wörtern — direkt in DB, beim nächsten Login sofort sichtbar.



LERNPLAN-GENERATOR

Personalisiert • gecacht • mit Zeitplan

Schwache Skills zuerst, gesperrte Skills nie in Woche 1, max. 3 Skills/Woche. 28-Tage-Cache im Browser.

ARCHITEKTUR & TECHNISCHE ENTSCHEIDUNGEN

Wie es zusammenspielt



KEY DECISIONS

- 1 ReAct-Agent statt hardcoded Flows**
Der Agent wählt *selbst* das richtige Tool je nach Frage — keine starren if/else-Flows. Neue Tools lassen sich ohne Code-Änderung am Router hinzufügen.
- 2 RunnableSequence für Code-Review**
LangChain-Pipe-Syntax ([step1](#) | [step2](#) | [step3](#)): Jeder Schritt bekommt den Summary des vorherigen als Kontext. *Chain-of-Thought* für Code-Qualität.
- 3 FAISS lokal statt Cloud-Vektordatenbank**
Kein externer Service nötig — PDF-Dateien werden lokal indexiert. *Setup in unter 30 Sekunden*, keine API-Kosten, kein Datenschutzproblem.
- 4 Eigene Memory-Implementierung**
ConversationSummaryMemory: LLM komprimiert Chat-Verlauf zu *max. 40 Wörtern* pro Turn. Kein wachsendes Kontext-Fenster, kein Token-Overflow.

Live Demo



~20S

Login & Dashboard



~60S

Tutor-Chat & Gedächtnis



~60S

Code Review



~45S

Skills & Übung



~30S

Lernplan

REFLEXION

Was ich **gelernt** habe — und was ich **anders machen würde**

GRÖSSTES LEARNING

Prompt Engineering ist der eigentliche Engpass

Nicht der Code — der *Prompt* entscheidet, ob die KI brauchbare Antworten gibt. Strikte Output-Formate (**JSON-only**), klare Rollenbeschreibung, Kontext-Management: das kostet mehr Zeit als alles andere.

Nebeneffekt: *Je besser das Prompt, desto weniger Code man braucht.*

PROMPT ENGINEERING



WAS ICH ANDERS MACHEN WÜRD E

Streaming von Anfang an — und echte Vektordatenbank

Streaming: Antworten kommen erst nach 3–8 Sekunden. Token-Streaming von Anfang an einzuplanen hätte die UX massiv verbessert — das Nachrüsten war aufwendiger als erwartet.

Vektordatenbank: FAISS ist gut für Prototypen. Für Produktion würde ich *pgvector* oder Qdrant nehmen — persistenter, skalierbarer, einfacher zu updaten.

ARCHITEKTUR



NÄCHSTE SCHRITTE

Was das Projekt noch braucht

Streaming-Antworten — Token-by-Token via Server-Sent Events, keine Wartezeit mehr.

Mehrsprachigkeit — das System ist auf Deutsch ausgelegt, aber der Skill-Tree und Übungen könnten auf Englisch erweitert werden.

Adaptive Schwierigkeit — Übungen automatisch an den aktuellen Score anpassen, nicht nur freischalten/sperren.

AUSBLICK